# 東南大學 編译原理课程设计 seuLex 设计报告

成员: 09013430 任杰文 09013429 黄路遥

09013413 钱鑫

东南大学计算机科学与工程学院

二 0 16 年 5 月

设计任务名称		SeuLex		
完成时间		2016/5/18	验收时间	
本组成员情况				
学号	姓名	承	担 的 任 务	成绩
09013430	任杰文	Lex 全部任务: 相关文档报告编	分析,设计,实现。	
09013429	黄路遥	YACC		
09013413	钱鑫	YACC		

注:本设计报告中各部分如果页数不够,请自行扩页。原则是一定要把报告写详细,能说明本组设计的成果和特色,能够反映小组中每个人的工作。报告中应该 叙述设计中的每个模块。设计报告将是评定各人成绩的重要依据之一。

## 1 编译对象与编译功能

## 1.1 编译对象

```
(作为编译对象的 C 语言子集的词法、语法描述)
    Cminus.1 文件内容如下:
%{
#include <fstream>
using namespace std;
typedef enum
    INT = 1,
    FLOAT,
    ID,
    STRUCT,
    IF,
    ELSE,
    RETURN,
    NUM,
    LPAREN,
    RPAREN,
    LCOMMENT,
    RCOMMENT,
    LBRACK,
    RBRACK,
    ASSIGN,
    SEMI,
    COMMA,
    MINUS,
    PLUS,
    TIMES,
    OVER,
    MOD,
    EQ,
    CHAR,
    BOOL,
    DOUBLE,
    VOID,
    _NULL,
    TRUE,
    FLASE,
    WHILE,
    PLUSASSIGN,
    MINUSASSIGN,
```

```
TIMESASSIGN,
      OVERASSIGN,
      MODASSIGN,
      LOGICNOT,
      LOGICAND,
      LOGICOR.
      NEQ,
      IT.
      GT,
      LEQ,
      GEQ,
      NL,
      SPACE,
      ERROR
} TokenType;
int lineno = 1;
%}
alpha
                  [A-Za-z]
                  [0-9]
digit
alphanum
                  [A-Za-z0-9]
%%
"int"
                  cout << seuLexLastLex << "\t at line " << lineno << "\t----\tPrimitive Type\n"; return INT;
                        cout << seuLexLastLex << "\t at line " << lineno << "\t----\tPrimitive Type\n"; return CHAR;
"char"
"bool"
                        cout < seuLexLastLex < < "\t at line " < lineno < < "\t----\tPrimitive Type\n";return BOOL;
"float"
                        cout << seuLexLastLex << "\t at line " << lineno << "\t----\tPrimitive Type\n";return FLOAT;
"double"
                  cout << seuLexLastLex << "\t at line " << lineno << "\t----\tPrimitive Type\n";return DOUBLE;
"void"
                        cout << seuLexLastLex << "\t at line " << lineno << "\t----\tPrimitive Type\n";return VOID;
"NULL"
                        cout << seuLexLastLex << "\t at line " << lineno << "\t----\tInternal Constant\n"; return_NULL;
"true"
                  cout << seuLexLastLex << "\t at line " << lineno << "\t----\tInternal Constant \n"; return TRUE;
                        cout << seuLexLastLex << "\t at line " << lineno << "\t----\tInternal Constant\n"; return FLASE;
"false"
"if"
                  cout << seuLexLastLex << "\t at line" << lineno << "\t----\trbow" Controller \n"; return IF;
                  cout < < seuLexLastLex < < "\t at line " < lineno < < "\t----\tFlow Controller\n";return ELSE;
"else"
"while"
                        cout << seuLexLastLex << "\t at line " << lineno << "\t----\tFlow Controller\n"; return WHILE;
                  cout < < seuLexLastLex < < "\t at line " < < lineno < < "\t---\tFlow Controller \n"; return RETURN;
"return"
{alpha}{alphanum}*
                        cout<<seuLexLastLex<<"\t at line "<<li>lineno<<"\t----\tIdentifier\n";return ID;</pre>
{digit}+("."{digit}+)?
                        cout < < seuLexLastLex < < "\t at line " < < lineno < < "\t---\tNumber\n";return NUM;
                  cout < < seuLexLastLex < "\t at line " < < lineno < < "\t----\tAssign Operator \n"; return ASSIGN;
                  cout << seuLexLastLex << "\t at line "<< lineno << "\t----\tAssign Operator\n"; return PLUSASSIGN;
```

```
"-="
                                           cout < < seuLexLastLex < < "\t
                                                                                                                        at
                                                                                                                                       line
                                                                                                                                                            "<<li>ineno<<"\t----\tAssign
                                                                                                                                                                                                                                        Operator\n";return
MINUSASSIGN:
 "*_"
                                           cout < < seuLexLastLex < < "\t
                                                                                                                        at
                                                                                                                                       line
                                                                                                                                                            "<<li>ineno<<"\t----\tAssign
                                                                                                                                                                                                                                        Operator\n";return
TIMESASSIGN;
"/="
                                           cout < < seuLexLastLex < < "\t
                                                                                                                                        line
                                                                                                                                                            "<<li>ineno<<"\t----\tAssign
                                                                                                                                                                                                                                        Operator\n";return
OVERASSIGN;
"%="
                                           cout < seuLexLastLex < "\t at line " < lineno < "\t----\tAssign Operator\n";return MODASSIGN;
                                           cout<<seuLexLastLex<<"\t at line "<<li>lineno<<"\t----\tArithmetic Operator\n";return MINUS;
                                           cout << seuLexLastLex << "\t at line " << lineno << "\t----\tArithmetic Operator\n";return PLUS;
                                           cout << seuLexLastLex << "\t at line " << lineno << "\t----\tArithmetic Operator\n";return TIMES;
                                           cout < seuLexLastLex < "\t at line " < lineno < "\t----\tArithmetic Operator\n";return OVER;
 "%"
                                           cout << seuLexLastLex << "\t at line " << lineno << "\t----\tArithmetic Operator\n";return MOD;
"!"
                                           cout << seuLexLastLex << "\t at line " << lineno << "\t----\tLogical Operator\n";return LOGICNOT;
 "&&"
                                           cout < seuLexLastLex < "\t at line " < lineno < "\t----\tLogical Operator\n"; return LOGICAND;
"||"
                                           cout < seuLexLastLex < "\t at line " < lineno < "\t----\tLogical Operator\n";return LOGICOR;
                                           cout < seuLexLastLex < < "\t at line " < lineno < < "\t----\tRelation Operator\n";return EQ;
                                           cout << seuLexLastLex << "\t at line " << lineno << "\t----\tRelation Operator\n"; return NEQ;
                                           cout << seuLexLastLex << "\t at line " << lineno << "\t----\tRelation Operator\n"; return LT;
                                           cout << seuLexLastLex << "\t at line" << lineno << "\t----\tRelation Operator \n"; return GT; and the country countr
 "<=
                                           cout < seuLexLastLex < "\t at line " < lineno < < "\t----\tRelation Operator\n";return LEQ;
                                           cout << seuLexLastLex << "\t at line " << lineno << "\t----\tRelation Operator\n";return GEQ;
 "!="
                                           cout < < seuLexLastLex < < "\t at line " < lineno < < "\t----\tSeparating Character\n"; return
COMMA;
                                           cout < < seuLexLastLex < < "\t at line " < lineno < < "\t----\tSeparating Character\n"; return SEMI;
                                           cout < < seuLexLastLex < < "\t at line " < lineno < < "\t----\tSeparating Character\n"; return
LCOMMENT;
                                           cout < < seuLexLastLex < < "\t at line " < lineno < < "\t----\tSeparating Character\n"; return
RCOMMENT;
                                           cout << seuLexLastLex << "\t at line" << lineno << "\t----\tSeparating Character \n"; return LPAREN; and the country country
 "("
                                           cout < seuLexLastLex < <"\t at line " < lineno < <"\t----\tSeparating Character\n";return RPAREN;
 ")"
                                           cout < < seuLexLastLex < < "\t at line " < lineno < < "\t----\tSeparating Character\n"; return LBRACK;
 "]"
                                           cout < < seuLexLastLex < < "\t at line " < lineno < < "\t----\tSeparating Character\n"; return RBRACK;
                                          lineno++;return NL;
\n
                                                          ;/*ignore white space*/return SPACE;
[" "\t\r]
                                               cout<<seuLexLastLex<<"\t at line "<<li>ineno<<"\t----\tBad Character\n"; return -1; return
ERROR;
%%
int main()
```

```
{
    ifstream in("demo.cpp");
    while( seuLex( in ) != -1 );
    cout << "Lexing Ended\n";
    system("pause");
    return 0;
}</pre>
```

#### 1.2 编译功能

(所完成的项目功能及对应的程序单元)

- FileReader 类: Cminus.1 文件读入,将其内容分割为 C 语言定义段,正规定义段,规则段(返回正规式及其对应 C++程序),用户子程序段。
- FormatRegExp:

根据 FileReader 类提供的正规定义、正规式,处理输入正规式,将正规式转化为标准表达形式:

只含有运算符:连接·,或 | ,闭包\*,正闭包+,一次或空 ? ,左小括号(, 右小括号)。

并且为了将普通符号与运算符区分开,用 ASCLL 码不用的常量整数替 换表示为:

```
const char STAR = 128;
const char ONE_OR_MORE = 129;
const char ONE_OR_NONE = 130;
const char AND = 131;
const char OR = 132;
const char LEFT_LITTLE_BRACKET = 133;
const char RIGHT_LITTLE_BRACKET = 134;
将标准化的正规表达式转为后缀形式,同时去掉小括号。方便求 NFA 运
```

- TransTable 类: 存放 NFA 状态转化表。
- NFA 类: 计算后缀正规表达式,通过 Thompson's Algorithm 将之转化为对应的 NFA (初始状态标号默认 0,状态数,状态转化表, Token 识别映射表)。
- MergedNFA 类:派生自 NFA,合并多个 NFA(初始状态标号默认 0,状态数,状态转化表,Token 识别映射表)
- DFA 类:对合并的 NFA 进行确定化,并最小化 DFA (初始状态标号,状态数,状态转化表, Token 识别映射表)
- CodeGenerator 类:

算。

- 生成程序框架:
- 根据 Cminus. 1 语言定义段生成包含头文件,变量声明等代码;
- 根据生成 DFA 生成状态转化表, Token 识别映射表;
- 根据初始状态标号,初始化初始状态;
- 根据 Cminus. 1 规则段生成识别对应 Token 执行的代码;
- 根据 Cminus. 1 用户子例程段生成用户子例程;

## 2. 主要特色

- 1) 正规定义段可接受定义形式:
  - a) alpha [A-Za-z]
  - b) digit [0-9]
  - c) alphanum [A-Za-z0-9]
- 2) 规则段中支持多种运算符:
  - 连接:省略表示
  - 或: | 表示
  - 闭包: \*表示
  - 正闭包: +表示
  - 一次或一次以上重复:? 表示
  - 一定范围的字符或运算:如[A-Z]表示 A|B|······|Z
  - 表示引用正规定义:如{alpha}表示引用[A-Za-z]
  - 表示优先级: ()
  - 运算符内容需作为普通符号使用只需加"":如"|"解释为字符串"|",而不表示或运算.从而能够识别左右中括号「];
  - 通配符表示任意字符:..
  - 生成的 C++程序文件名为 yylex. cpp
  - 生成程序中有提供 int seuLex(instream & in, ostream & out)函数原型,返回 值为 cminus.1 中定义的 Token 类型,文件结束时,返回-1;供语法分析程序调用。

### 3 概要设计与详细设计

(由总到分地介绍 SeuLex 的设计,包括模块间的关系,具体的算法等。采用面向对象方法的,同时介绍类(或对象)之间的关系。在文字说明的同时,尽可能多采用规范的图示方法。)

#### 3.1 概要设计

(以描述模块间关系为主)

- 1) Seulex 共包含 7 个类文件,一个 header.h 文件和一个 main 函数文件;
- 2) 其中 header.h 中声明了包含的头文件,以及定义了常量:
  //用 ASCLL 码不用的常量整数表示:闭包、正闭包、或空串、与、或、空串

const char STAR = 128;

const char ONE\_OR\_MORE = 129;

const char ONE\_OR\_NONE = 130;

const char AND = 131;

const char OR = 132;

const char LEFT\_LITTLE\_BRACKET = 133;

const char RIGHT\_LITTLE\_BRACKET = 134;

//定义空串 ascll 码为 0

const char EPSILON = 0;

//定义 NFA 状态转化表列数,即 NFA 可接收符号数(为 ASCLL 码 0 - 127)

const int NUM\_OF\_COLUMNS = 128;

- 3) main 函数文件定义了程序的入口,调用各个类,将读入的 cminus.l 解析,构造 NFA, DFA,生成词法分析程序。
- 4) FileReader 类: Cminus.l 文件读入,将其内容分割为 C 语言定义段,正规定义段,规则段(返回正规式及其对应 C++程序),用户子程序段。
- 5) FormatRegExp: 根据 FileReader 类提供的正规定义、正规式,处理输入正规式,将正规式转化为内码表示运算符的标准后缀表达形式;
- 6) TransTable 类: 存放 NFA 状态转化表。
- 7) NFA 类:利用 FormatRegExp 提供的后缀表达式,通过 Thompson's Algorithm 将之转化为对应的 NFA (初始状态标号默认 0,状态数,状态转化表, Token 识别映射表)。
- 8) MergedNFA 类:派生自 NFA,合并多个构造好的 NFA(初始状态标号默认 0,状态数,状态转化表,Token识别映射表)
- 9) DFA 类:对 MergedNFA 进行确定化,并最小化 DFA (初始状态标号,状态数,状态转化表, Token 识别映射表)
- 10) CodeGenerator 类:根据 FileReader, DFA 结果生成相应的词法分析程序。

#### 3.2 详细设计

(以描述数据结构及算法实现为主)

1) FileReader 类: Cminus.l 文件读入,将其内容分割为 C 语言定义段,正规定义段,规则段(返回正规式及其对应 C++程序),用户子程序段。函数原型如下:

//返回 C 语言定义部分代码

vector<string> getDefPart();

//返回正规定义段

map<string> getRegDefPart();

//返回正规表达式

vector<string> getRegularExpression();

//返回正规表达式后对应代码

vector<string> getCode();

//返回用户定义子例程

vector<string> getLastPart();

2) FormatRegExp: 根据 FileReader 类提供的正规定义、正规式,处理输入正规式,将正规式转化为内码表示运算符的标准后缀表达形式;函数原型如下:

FormatRegExp( const map<string, string> &RDP);

~FormatRegExp();

//将正规表达式中缀转后缀

string postfix( string regExpr );

//预处理: 处理双引号,大括号,中括号,通配符,转义字符:"{}[].\ 并将运算符转为内码: 只包含内码表示的 ()+\*?|&

string preProcess(string s);

//处理中括号,将中扩号中内容用 | 运算符连接起来,并用 ()表示优先运算

string proBrackets( string s);

//处理转义字符

char escape( char d );

//一元运算符

bool isUniOp(char c);

//二元运算符

bool isBinOp(char c);

成员变量:

//cminus.l 正规定义

map<string> regDefPart;

算法描述: 首先用正规定义部分初始化类; 此类提供唯一一个 public: 成员函数 string postfix( string regExpr ); 此函数首先调用预处理 string preProcess(string s);处理并去掉双引号,大括号,中括号,通配符,转义字

符:"{}[].\; 并将运算符转为内码:只包含内码表示的 (、)、+、\*、?、 |、连接(&); 在中缀转后缀时,利用堆栈和算符的优先级进行转化。

3) TransTable 类: 存放 NFA 状态转化表。

成员变量:

//状态转化表行数(状态数)

int numRows;

//存储 hash\_set<int>指针的二维数组

vector<vector<hash set<int>\*> > tableItems;

此类用作 NFA 状态转化表,由于每个状态接收同一个字符时可能有不同的转移状态,所以用一个 Item 是集合的二维数据来存放,为了空间换时间,使用 hash\_set;

4) NFA 类:利用 FormatRegExp 提供的后缀表达式,通过 Thompson's Algorithm 将之转化为对应的 NFA (初始状态标号默认 0,状态数,状态转化表, Token 识别映射表)。

主要成员函数:

//构造函数

NFA();

NFA( int \_numState );

NFA( string regExpr , const map<string, string> &regDefPart);

//NFA 运算

NFA\* or(NFA \*m, NFA \*n);

NFA\* and(NFA \*m, NFA \*n);

NFA\* star(NFA \*m);

NFA\* oneMore(NFA \*m);

NFA\* oneNone(NFA \*m);

在用正规式构造 NFA 时,用正规式和正规定义初始化,NFA 调用FormatRegExp 类,标准化正规表达式,并中缀转后缀,操作符用 header 中的内码替换;然后利用后缀表达式和堆栈构造 NFA。

5) MergedNFA 类:派生自 NFA,合并多个构造好的 NFA(初始状态标号默认 0,状态数,状态转化表,Token识别映射表)成员函数:

//合并 NFA

MergedNFA ( const vector<NFA\*> &nfas );

//返回当前 NFA 状态识别的 Token 编号, 低编号具有高优先级 int statePatten(int s);

算法描述: NFA 重新编号, 计算合并 NFA 状态数, 设置识别 TOKEN 的接收态集合,构造新的状态转化表,添加生成 NFA 初态到各 NFA 初态的 EPSILON边, 复制其它转化函数;

6) DFA 类:对 MergedNFA 进行确定化,并最小化 DFA (初始状态标号,状态数,状态转化表, Token 识别映射表)函数原型:

//用 NFA 构造 DFA

DFA( MergedNFA \*pnfa);

//返回当前 DFA 状态识别 Token 编号, 低编号具有高优先级 int statePatten( hash\_set<int>\* curStateOfDFA );

//返回集合 T,接收 a 后转化状态集

hash\_set<int>\* move(hash\_set<int>\* T, char a);

//返回状态 i 的 EPSILON 闭包

hash\_set<int>\* epsilonClosure (int i);

//返回一个 NFA 状态集合的 EPSILON 闭包

 $hash\_set < int>* epsilonClosure( \ hash\_set < int>* \ curSetOfNFAStates \ );$ 

//返回 DFA 状态数

int getNumStates();

//返回状态转化表

vector<vector<int >>\* getTable();

//返回 DFA 识别模式表

vector<int >\* getStatePattern();

//DFA 最小化

void minimize();

//根据出边划分子集

bool partition( vector<set<int>\* >\* statesOfMinimizedDFA, map<int,int>& oriStateToMinimizedState);

//获取 DFA 初始状态

int getEnterState();

算法描述:

NFA 确定化:定义:DFA 闭包、DFA 闭包标号、闭包之间的转化映射关系(表),vector为 128 维,对应 128 个 ASCLL 码;初始化:将 EPSILON闭包标号,作为 DFA 的状态、添加 DFA 状态、添加闭包间映射关系;当存在新的 DFA 状态时,遍历所有现有 DFA 状态,为每一个 DFA 状态添加转化函数,并把出现的新状态加入 DFA 集合中:把出现的新状态加入 DFA 集合中:求当前转换的 EPSILON闭包,加入新的 EPSILON闭包作为 DFA状态,标号、加入新的 DFA 状态、添加闭包间映射关系。DFA 状态数、初始化状态转化表、初始化识别 TOKEN表。遍历所有 DFAState,标记当前 DFA 状态所识别的 token,构造状态转化表。

DFA 最小化: 计算 DFA 可识别 Token 数,定义:最小化 DFA 状态集合及其编号、原 DFA 状态映射到最小化 DFA 的某个状态;初始化:初始化非终态与终态集合;插入最小化 DFA 初始状态集,并初始化新旧状态映射表;自顶向下划分;构造新状态转化表、新状态与识别 Token 映射表;更新 DFA。

7) CodeGenerator 类:根据 FileReader, DFA 结果生成相应的词法分析程序。函数原型:

//打开文件,并包含头文件

CodeGenerator(string fileName);

~CodeGenerator();

//根据规则,生成驱动程序,默认入口状态为0 void genDriver( vector<string> rules,int enterState = 0); //将二维 vector 转化为二维常量数组 void genTable(vector<vector<int> > t,string); //将 vector 转化为常量数组 void genVector(vector<int> v,string); 算法描述: 首先,用 yySeuLex.cpp 文件初始化类,打开写入文件;生 成一些包含头文件的代码;根据 Cminus.l语言定义段生成 C语言定义段; 根据 DFA 状态转化表生成 DFA 状态转化表;根据 DFA 状态 Token 映射表 生成 DFA 识别 token 查找表;根据 Cminus.l 规则段生成驱动程序;根据 Cminus.1用户子例程段生成用户子例程段;

## 4 使用说明

## 4.1 SeuLex 使用说明

1. cminus.l 定义规则:

正规定义段可接受定义形式:

a) alpha [A-Za-z]b) digit [0-9]

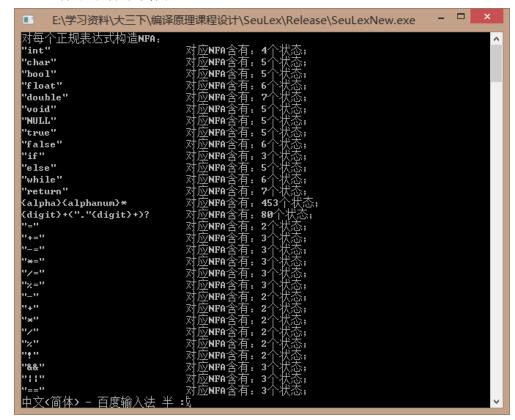
c) alphanum [A-Za-z0-9]

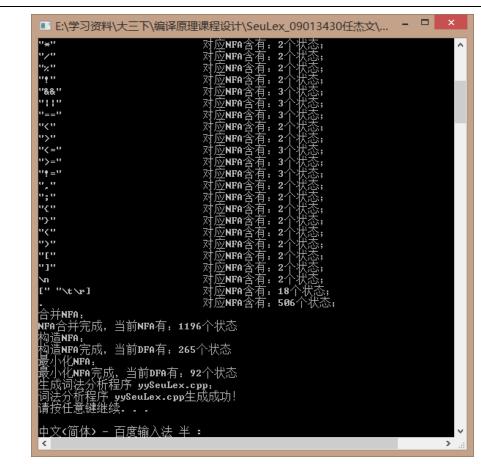
规则段中支持多种运算符:

- 连接:省略表示
- 或: 表示
- 闭包: \*表示
- 正闭包: +表示
- 一次或一次以上重复:? 表示
- 一定范围的字符或运算:如[A-Z]表示 A|B|·····|Z
- 表示引用正规定义:如{alpha}表示引用[A-Za-z]
- 表示优先级: ()
- 运算符内容需作为普通符号使用只需加"":如"|"解释为字符串"|",而不表示或运算
- 通配符表示任意字符:..
- 生成的 C++程序文件名为 yylex. cpp
- 2. 程序输出词法分析文件为: yylex.cpp;
- 3. 生成程序中有提供 int seuLex(instream & in, ostream & out)函数原型,返回值为 cminus.l 中定义的 Token 类型,文件结束时,返回-1;供语法分析程序调用;
- 4. VS2012 编译通过;

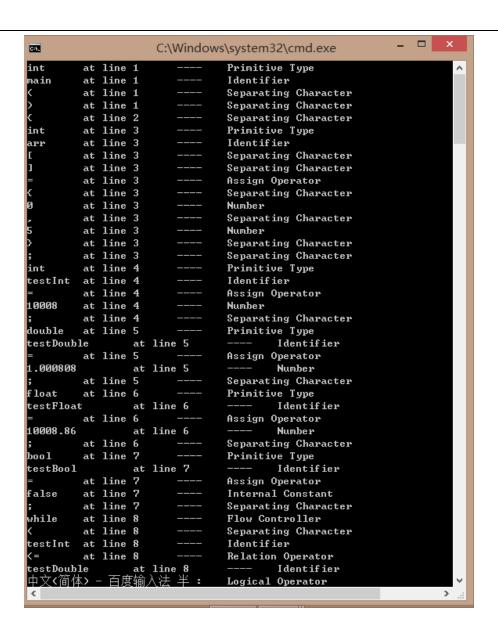
## 5 测试用例与结果分析

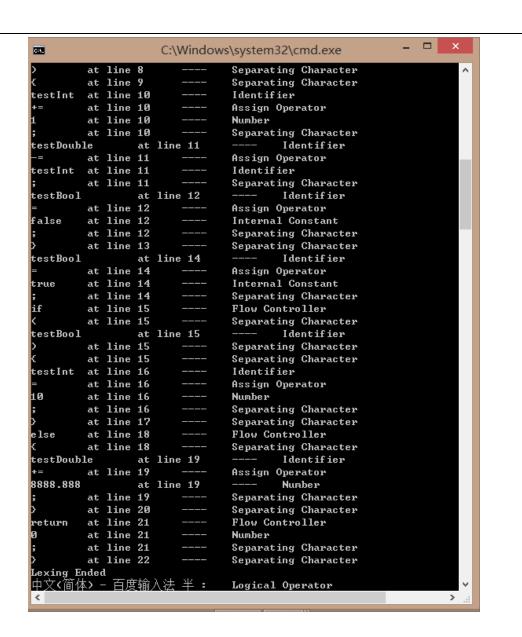
- 1. 测试用例词法定义为 cminus. 1。具体内容见文件中;
- 2. 测试用例示例程序为 demo.cpp, 具体内容见文件中;
- 3. 生成 yylex, 距离代码见文件;
- 4. Lex 运行结果屏幕截图:





5. 词法分析结果频幕截图:





6 课程设计总结(包括设计的总结和需要改进的内容)	
在本次编译原理 Lex 和 Yacc 项目完成过程中,我们组的成员都对编译原理及构造过程有了更深一步的了解。同时,我们也进一步提高了自己编写程序的能力,并锻炼了自己与他人合作的能力。	
程序还有些不足的地方,比如,lex 中为了识别正规是中支持的运算符,在很分需要对运算符进行特殊处理,给程序设计的模块合理划分带来一定问题,不利于程拓展。	
7 教 师 评 语	
签名:	

附:包含源程序、可运行程序、输入数据文件、输出数据文件、答辩所做 PPT 文件、本设计报告等一切可放入光盘的内容的光盘。